

AIC·AI + 集成电路技术报告（工作稿）

作品名称：ICARUS数字IP验证智能体

定位：面向数字 IP 的 RTL 自动验证工具

日期：2026-10-04

已验证源码版：867b8bd，核心采样保护来自 1c1e0dc；本次另修复 PDF 混排及列表排版。历史 12326a2 联调、各次验收与在线 pilot 分别保留版本和原始记录，不能把历史成绩自动归到当前版本。

本稿按官方七节大纲组织，尚未定稿。机器验收、真实 API 实验和代理交叉检查已登记，没有可公布的真人试用和独立人工复核结果。提交前确认团队编号、最终版本与材料规格。

一、作品概述

1.1 背景与问题

数字 IP 开发需要判断 RTL 是否符合接口和时序行为要求。能编译只说明工具接受代码，不能说明复位、边界条件、握手或状态转移正确。通用模型可以协助提出输入序列，但模型同时生成的预期输出需要独立核对；否则计划合法、仿真成功和功能正确容易被混为一谈。

本项目将需求限定在设计阶段的模块级功能验证，提供从规格和接口到输入计划、真实仿真、结果解释与证据导出的工作流。首批对象为需要验证小型数字 IP 的开发者和学习者。复杂 SoC 验证、时序签核、形式验证及制造测试不属于本版本目标。

1.2 目标与作品形态

用户选取案例或上传 RTL，确认接口与验证目标后，模型通过 API 提出测试输入；系统校验动作并调用本地 Icarus。具备参考模型时，由确定性逻辑生成期望结果并比较实际输出。模型读取摘要后追加测试，直到发现反例、主动停止、遇到错误或预算耗尽。

作品包含 Streamlit 网页、CLI、Python 验证库、案例与规则、实验脚本。开源交付支持复现和二次开发；参赛主线是 AI 对集成电路设计验证流程的辅助作用。

目标分为三个层次：

层次	验收内容	当前证据状态
可运行	API 生成计划、真实仿真、反馈补测与证据保存	内置单模块与四类模块真实API pilot已完成；外部类型化采样修复及1请求/2轮真实API联调已完成
可核验	期望值来源、输入版本、失败与停止原因可追溯	代码、回归及联调记录可查；原始目录需随交付打包
有增益	在相同预算上限下改善缺陷检出、减少无效操作	反馈Agent为4/8，高于单次/无反馈的2/8，但低于固定/随机5/8；仅为单次开发集观察

二、需求分析

2.1 需求拆解

具体任务	难点	产品响应	尚需补充的使用证据
验证复位、使能、边界与握手	合法输入不一定覆盖关键行为	规格约束计划，保留旧向量并追加测试	实际 RTL 使用者如何选择验证目标
理解失败	编译错误、仿真错误与功能差异含义不同	分别保留错误、检查记录与波形	使用者能否正确解释“未发现差异”
复查 AI 提出的测试	模型输出可能结构不合法或判断不可靠	Schema 门禁、独立期望值、动作权限限制	补测是否覆盖了原计划遗漏的场景
控制执行成本	多轮调用和重复仿真消耗时间与用量	请求、轮数、激励周期与超时限制	在真实任务中的等待是否可接受
复现同一结论	输入或版本变化后旧结果可能失效	输入哈希、轨迹、每轮产物与状态清理	异机是否可从证据包重放

这些是依据已有程序和实验问题形成的需求假设，不能描述为已完成行业调研。历史外部 UART 实验中，位序回文输入未暴露位序缺陷，正常帧未暴露停止位检查缺陷；补充输入后才能观察到差异。这支持“输入选择影响可检出范围”，不代表自动 Agent 已解决该问题。外部模块记录

2.2 待收集的需求与试用证据

真人需求记录需包含角色、开发关系、具体任务、现用方法、遇到的事实、希望改善的步骤及匿名引用授权。暂不填写人数、原话、满意度、节省时间或效率百分比。

建议由 3–5 位未参与对应功能开发的使用者各执行 3–5 个任务；人数仅是本项目建议。优先覆盖新手、RTL 开发者和技术复核者。沿用真人试用材料，将首次失败、协助和复测分开记录。独立技术复核另按复核指南进行。

自动化回归检验预定行为；代理操作与代理交叉检查可发现界面或逻辑问题；真人试用反映真实使用过程；独立人工复核判断规格、判据和结论是否成立。四者分栏保存，不能相互冒充。

三、AI 技术工具选择与运用

3.1 模型与工具角色

当前在线联调采用第三方模型 API，配置模型 ID 为 deepseek-flash。不在本机部署模型，不宣称自行训练基础模型权重。选用 API 是为了复用语言与推理能力，将工程工作集中于验证约束、执行与证据管理。模型名称及当次配置以轨迹为准，服务商后续更新不能追溯覆盖历史记录。

Icarus 负责编译和执行测试台；其退出成功本身不构成功能正确证据。独立参考模型提供当前支持模块的期望输出，比较逻辑给出检查结果。Python/Pydantic 负责类型与动作约束，Streamlit 提供操作入口。第三方来源及许可参照项目资源清单，发布时附对应版本。

3.2 模型可以做什么

模型输入包括人工规格、接口合约、现有计划、最近一轮仿真摘要和剩余预算。允许动作是追加输入向量或停止。不得输出 shell 命令、改 RTL、改参考模型、替换旧向量或指定期望输出。新增动作通过校验后才进入仿真。

模型提供候选测试，不能为自身输出建立可信判据。内置流程缺少独立参考判据时停止并提示证据不足，不把生成的期望值当作真值。新增外部流程采用明确不同的 qualified_baseline_differential：基线先通过已有有限规格检查，再在同一输入下比较限定输出。它报告 behavior_difference，不将差异直接标为功能反例。预算耗尽和未发现差异均不代表全部行为正确。

四、项目实施

4.1 执行流程

```
RTL + 人工规格 + 接口合约
↓
API 提议追加输入 / 停止
↓
结构、动作、输入哈希及预算检查
↓
生成测试台 → Icarus 编译与仿真 → 独立判据比较
↓
保存计划、日志、波形、检查结果与轨迹
↓
反例 / 错误 / 证据不足 / 预算耗尽：停止
否则：将摘要反馈给 API，继续下一轮
```

4.2 关键实现与改进点

1. 将输入提出和结果判断分开。模型负责测试输入，确定性参考模型负责期望输出；判据的支持范围对用户可见。参考模型本身仍需独立核查。
2. 在真实仿真反馈上补测。后续动作保留已有输入，以追加方式扩展计划。遇到反例保留现场，不通过改变预期结果掩盖失败。
3. 以可复核的运行记录约束自动化。每轮保存实际计划、检查数、失败数、停止原因和输入哈希，使模型建议与执行事实分开。
4. 明确有限预算。请求失败也消耗调用尝试；累计激励周期计入每轮重放的旧计划。它不包含全部复位开销，不是代码覆盖率，也不是金额封顶。

这些是本项目的工程设计和差异化组合，不据此宣称“业内首创”或“替代验证工程师”。已有单次开发集消融不足以证明反馈机制的普遍价值，仍须增加重复与独立留出任务。

4.3 状态、异常与安全边界

网页保留同会话页面切换和 rerun 的结果；设计输入变化会清除相关旧页面证据，磁盘记录保留。新执行使用新目录，避免覆盖历史轨迹。API 输出不合法、截断、网络错误和仿真错误分别记录。密钥由本机私有配置读取，不能写入提交材料。

轨迹默认在本地忽略目录中，不自动上传训练。候选数据导出仍待人工标注；本次没有模型微调成果。运行时间预算在操作间检查，单次 API 与仿真另设超时，不宣称严格可中断所有阻塞。

当前内置判据另收紧两项语义：顺序逻辑的 before 采样不再给出 reference_model 判定，而是明确缺少证据；输入向量未重复列出的值按测试台语义保持先前值。这是源码提交 1c1e0dc 的修正，下面60行 pilot 仍为 e9b7b8a 冻结运行，未在新判据下重新实验，不能把旧成绩当成新源码的能力成绩。

4.4 外部 RTL 类型化适配

外部输入先按清单验证源码哈希，再运行已有规格测试确认基线在这些检查下零失败。适配器目标是在测试台实际采样时刻比较顶层限定输出；对于 valid 为零且规格未定义的数据，不比较其无效载荷。初版从 VCD 同一时间戳读取最终值，后续自审发现这不一定等于采样语句瞬间值：下一向量引起的组合变化可能污染采样。现已改为采样语句之后、下一组输入之前记录即时快照，并保存插桩前后测试台和哈希；锚点或样本数不符即拒绝。初版优先编码器16个采样点中实际发现4个与快照不同，旧证据保留，新目录重

新验收。历史外部 UART TX 与内置案例同名，适配器显式禁用不适用的内置参考模型映射。

外部证据的 checks/failures 保持零，另列 compared_samples/differences，不将波形样本伪装成独立断言。候选和基线各消耗一次仿真预算；规格资格检查与复位开销另行披露。即时快照修复后24项适配测试通过，外部UART RX真实API联调已完成1请求、2轮；完整事实见第五节。外部适配说明

4.5 多模块 pilot 与后续正式实验

冻结模块、变体、判据和版本后，比较固定输入、随机输入、单次 API、多轮无反馈 API 与多轮反馈 Agent。对齐累计激励周期，披露实际请求、token、耗时与失败。至少分别统计参考实现误报、变体检出、不可判定和未执行；多条失败检查不能当作多个独立缺陷。

当前 pilot 预注册四类模块、八个缺陷、五种策略，共六十个样本，单次重复；以相同累计激励周期上限比较，不宣称实际周期、采样次数、token 或总耗时完全相同。多周期向量只在结束时检查，随机逐周期输入的采样更密；发现反例即停止，因此后续反馈主要是无差异摘要，不能宣传为失败日志驱动修复。首轮因接线配置问题主动停止并单列，新目录 .iverilog-ai/agent-comparison-live-chat-v2/ 已完整结束，52次实际请求，冻结输入变化列表为空，结果见第五节。协议、代理交叉检查

开发时已查看过的设计不能重新包装成独立留出集。若多轮次数不同，不比较累计并集来宣称同预算优势。保留全部预定任务及失败，不挑选“理想但不完美”的样本。任何重跑记录修正原因、版本与首次结果。

五、应用成效

5.1 已有证据及其边界

证据	实际结果	能支持的结论	不能支持的结论
历史内置手写测试台基准	15 案例、83/83 缺陷检出，0 误报、0 不可判定	该批输入与判据能够区分指定变体	AI 检出率为 100%
历史离线规则计划 + 参考模型	76/83；无期望值组 0/83、零可比较检查项	独立期望值在此执行链中必需	大模型能力或反馈 Agent 增益
历史在线规划共同五轮事后子集	在线并集 61/67，随机 57/67；单轮均值 83.9% 与 78.2%；固定单轮 85.1%	该开发集和子集下的描述性差异	普遍优于人工、独立留出结论
2026-10-04 真实 API Agent 联调	3 次请求，首次出现 1 次结构校验失败；修正后完成追加测试	单模块接口及反馈流程可运行	多模块可靠性、模型训练效果
已知计数器回绕缺陷回放	无新增 API 请求，12 项检查中 8 项不一致	保存的计划可暴露这一已知缺陷	检出 8 个缺陷或 AI 新发现缺陷
对应工程回归	211 项相关测试通过	该次范围内的工程行为符合检查	全仓回归、真人满意度或工业认证
当前机器功能验收	22 项通过；另有工具缺失/恢复真实退出码 2/0；285 份产物哈希一致	所选本机 UI/CLI 路径及原件完整性	22 人试用、真实触摸测试、最终冻结版全部功能已验收
外部开发集真实重放	24 输入：15 different、6 identical、3 inconclusive；规格测试检出 13/15 人工变体	冻结历史输入的可重放差分及有限规格检查	发现 15 个上游真实缺陷，或差分等于规格正确性
外部类型化适配修复验收	24项测试通过；新即时快照目录重新观察547个输出比较中的1处UART RX位序差异	修复后的有限采样与差分路径可执行	547个独立缺陷、普遍正确性或真实API增益

历史数字来源：指标总账。真实联调来源：API 联调记录。此表保留版本口径，不因后续功能完成自动扩大结论。

新增证据分别见机器验收、外部冻结重放、外部适配验收。各次工程测试范围可能重叠，不相加成新的独立测试总数，更不能相加成人数。机器验收的产物哈希未完整冻结被测源码，不能单凭 285 文件一致性声称当前最终提交已异机复现。外部规格测试仍漏检 UART TX 的两个历史变体，保留为局限。

5.2 新多模块真实 API pilot

策略	检出/固定缺陷分母	缺陷样本不可判定/ 未完成	实际请求数	全策略样本实际检查项
固定模板	5/8	0	0	615
逐周期随机	5/8	0	0	1,584
单次API	2/8	5	12	152
反馈Agent	4/8	0	19	306
无反馈Agent	2/8	3	21	247

完整60行保留，实际52次请求；全部请求均有usage，已知总用量234,536 tokens，实付费用未知。表中请求和检查项包含正确基线及缺陷样本，不是单个设计预算。反馈组的缺陷不可判定为0不代表该策略完全无失败：其正确基线样本仍出现2次截断及1次假警。单次API有1个正确基线假警及2个变体参考回放否决，分别披露，不混成同一个误报率。

反馈Agent本轮4/8高于单次API和无反馈的2/8，但没有胜过固定及随机的5/8；三种API策略对UART的两个缺陷均为0/2。只有一次开发集重复、实际采样强度不同，不能据此证明反馈机制的因果增益或普遍优于传统方法。实测记录、重算摘要

5.3 外部UART RX真实API联调

真实服务商调用1次、Icarus执行2轮，累计782个双侧激励周期，usage为5,661 tokens。已有固定计划182周期/侧，547个有效输出比较；追加4个向量后209周期/侧、628个比较，两轮均0差异。资格规格检查11项通过；候选和基线为相同冻结字节，所以这里只证明追加输入、双侧仿真和记录链可运行，不证明准确率。

另用固定和API扩展计划离线重放历史位序变体，两者均在cycle80、836ns观察到同一差异（数据150与105）。固定计划本来就能发现它，不能归功于新增AI向量，也不能称为API新发现缺陷。周期计入重放，资格检查和复位开销另列；达到轮数上限而停不证明完整正确性。真实联调记录、原件核查摘要

5.4 当前工程与浏览器验收

源码 867b8bd 在 PDF 排版修正后的完整回归为914通过、1跳过、0失败，227.34秒；之前核心采样保护版 1c1e0dc 为914/1、211.47秒，两份日志分别保留，见当前验证记录。这些数量与历史211、22或24项可能重叠，不能相加为新的去重测试总数。更早一次因测试临时目录位于仓库内而触发目录检查失败；仅调整临时目录后重跑，未为取得通过削弱断言，原失败另保留。

浏览器机器验收覆盖1440×900、1920×1080桌面与390×844手机模拟宽度，未见横向溢出；实际上传ALU、离线生成计划、执行84项检查通过，切页返回保留结果。这是自动化浏览器操作，不是真人体验，也不是实际手机硬件验收。

5.5 真实失败与修正

首次联调的第二次响应结构校验失败。原记录仅保留异常类别，没有足够字段诊断及用量，无法确认具体错误字段或是否截断。后续同时调整提示词约束与输出上限，并补充安全诊断；不能把成功单独归因于某一项改动。有效响应已记录的 token 不包含首次失败请求的未知用量，不充当总账单。

另一次多模块首轮 runner 使用的默认协议与此前联调配置不同，执行者主动停止。原始 60 行保留；有 7 次已记录响应、51,433 个已知 tokens，另有一次可能在途请求状态与用量未知。观测到截断和 JSON 校验失败，但没有可重放正文，不能认定协议差异是所有错误的唯一原因。该轮是接线失败开发记录，不并入后续完整 pilot。首轮停止记录

5.6 当前缺少的成效证据

真人使用时间、无人协助完成率与独立人工复核尚未形成本文可引用的完整证据。内部pilot、外部即时采样与真实API联调已有记录，但新内置判据修正后的能力重测、更多重复、独立留出集和有限规格判据人工核验仍待完成。后续新增结果应提供完整任务清单、原始文件哈希、复现入口、失败分类和版本；不得只写一个最终成功率。

没有实测经济效益，本文不填写节省人力、降低成本或量产收益。当前价值在于提供可执行、可追踪的模块验证流程；能否减少真实使用者工作量需要试用确认。

六、总结与展望

本作品已将第三方 API 的输入规划与本地 RTL 仿真结合，形成带判据和预算约束的自动补测流程。工程实现、历史基准、单模块联调及四类模块pilot具备记录。本轮反馈Agent没有胜过固定和随机策略，改进方向须以实际漏检、输出失败和判据假警为依据。不同证据不能合并成更强的准确率主张，也没有本地模型权重训练成果。

主要局限是参考判据支持范围有限、模型输出存在失败、开发集与留出集仍需严格划分，以及缺少真实用户和外部人工核查。正式报名/赛道变更、远程开源发布和最终提交包验收仍待完成，本机Git提交不等于已公开发布。短期优先扩展模块及判据、完成反馈消融、处理用户实际卡点；之后再评估托管微调是否带来可重复收益。上板、形式验证和商用签核兼容性属于后续研究方向，不作为本版本已交付能力。

以下为附录

七、附录

7.1 核心代码与复现入口

内容	仓库路径
Agent 状态和预算循环	src/iverilog_ai/ai/agent.py
API Provider	src/iverilog_ai/ai/provider.py
参考判据	src/iverilog_ai/core/reference_model.py
仿真流水线	src/iverilog_ai/core/pipeline.py
网页	ui/app.py
Agent CLI	scripts/run_verification_agent.py
外部类型化 Agent CLI	scripts/run_external_verification_agent.py
使用与预算说明	docs/experiment/api_agent.md
候选轨迹导出	scripts/export_agent_trajectories.py

操作命令与环境以使用文档为准；真实 API 需要使用者自备合法凭据。Git 忽略目录内的历史证据不随干净克隆自动取得，冻结提交包时须另行收录脱敏产物及清单，不可把“有脚本”写成“异机已复现”。

7.2 官方依据

本稿于 2026-10-04 实际查阅以下官方文件；作品适配“芯片智能设计/综合创新”是项目对方向的解释，报名归类以组委会确认及系统选项为准。

- AI + 集成电路主题赛通知
- 竞赛规则及作品提交要求
- 技术报告参考大纲

正式提交前的差距和文件规格见 gap_checklist.md，报名短文本见 submission_text.md。